

Policy gradient theorem的证明

如今，强化学习基本都采用参数化的神经网络来学习一个策略，而神经网络一般是通过梯度下降法或者各种变种来优化的，因此，获取累积回报关于策略的梯度至关重要。本节会给大家推导策略梯度的表达式，并介绍实际训练中是如何采样近似该表达式的。

这里我们首先额外引入一下动作价值函数的定义

$$Q(s_t, a_t) = E_{s_{t+1}, a_{t+1}, \dots} \left[\sum_{l=0}^{\infty} \gamma^l r^{t+l} \right]$$

即在状态 s_t 下采用动作 a_t 后，后续动作服从策略 π 的情况下的累积期望回报，其中 $\gamma \in (0, 1)$ 是折扣因子。

接着，我们将策略梯度计算过程详细展开如下：

$$\begin{aligned} \nabla_{\theta} J(\theta) &= \nabla_{\theta} V(s_0) \\ &= \nabla \left[\sum_{a_0} \pi(a_0 | s_0) Q_{\pi}(s_0, a_0) \right] \\ &= \sum_{a_0} [\nabla \pi(a_0 | s_0) Q_{\pi}(s_0, a_0) + \pi(a_0 | s_0) \nabla Q_{\pi}(s_0, a_0)] \\ &= \sum_{a_0} \left[\nabla \pi(a_0 | s_0) Q_{\pi}(s_0, a_0) + \pi(a_0 | s_0) \nabla \sum_{s_1, r_1} p(s_1, r_1 | s_0, a_0) (r_1 + \gamma V(s_1)) \right] \\ &= \sum_{a_0} \nabla \pi(a_0 | s_0) Q_{\pi}(s_0, a_0) + \sum_{a_0} \pi(a_0 | s_0) \sum_{s_1} p(s_1 | s_0, a_0) \cdot \gamma \nabla V(s_1) \\ &= \sum_{a_0} \nabla \pi(a_0 | s_0) Q_{\pi}(s_0, a_0) \\ &\quad + \sum_{a_0} \pi(a_0 | s_0) \sum_{s_1} p(s_1 | s_0, a_0) \cdot \gamma \sum_{a_1} \nabla \pi(a_1 | s_1) Q_{\pi}(s_1, a_1) \\ &\quad + \sum_{a_0} \pi(a_0 | s_0) \sum_{s_1} p(s_1 | s_0, a_0) \cdot \gamma \sum_{a_1} \pi(a_1 | s_1) \sum_{s_2} p(s_2 | s_1, a_1) \gamma \nabla V(s_2) \\ &= \sum_{a_0} \nabla \pi(a_0 | s_0) Q_{\pi}(s_0, a_0) \\ &\quad + \sum_{a_0} \pi(a_0 | s_0) \sum_{s_1} p(s_1 | s_0, a_0) \cdot \gamma \sum_{a_1} \nabla \pi(a_1 | s_1) Q_{\pi}(s_1, a_1) + \dots \\ &= \sum_{s_0} Pr(s_0 \rightarrow s_0, 0, \pi) \sum_{a_0} \nabla \pi(a_0 | s_0) \gamma^0 Q_{\pi}(s_0, a_0) \\ &\quad + \sum_{s_1} Pr(s_0 \rightarrow s_1, 1, \pi) \sum_{a_1} \nabla \pi(a_1 | s_1) \gamma^1 Q_{\pi}(s_1, a_1) + \dots \end{aligned}$$

$$\begin{aligned}
&= \sum_{s_0} Pr(s_0 \rightarrow s_0, 0, \pi) \sum_{a_0} \pi(a_0 | s_0) [\gamma^0 Q_\pi(s_0, a_0) \nabla \log \pi(a_0 | s_0)] \\
&+ \sum_{s_1} Pr(s_0 \rightarrow s_1, 1, \pi) \sum_{a_1} \pi(a_1 | s_1) [\gamma^1 Q_\pi(s_1, a_1) \nabla \log \pi(a_1 | s_1)] + \dots \\
&= \sum_{t=0}^{\infty} \sum_{s_t} Pr(s_0 \rightarrow s_t, t, \pi) \sum_{a_t} \pi(a_t | s_t) [\gamma^t Q_\pi(s_t, a_t) \nabla \log \pi(a_t | s_t)]
\end{aligned}$$

其中 $Pr(s_0 \rightarrow s_t, t, \pi)$ 代表：从状态 s_0 出发，且按照策略 π 与环境交互（rollout），在 t 时刻到达状态 s_t 的概率。

通过上述的推导，我们就得到了**无限长时间步**下的策略梯度的表达式，对于**有限长时间步**的环境，我们可以做一个简单的转化，把它变成无限长，从而同样适用上述公式。假设时间步长度为 T ，对于所有可能出现在最后一步的状态 s_{T-1} ，我们定义：

1. 从 s_{T-1} 出发，不论采取什么动作，一定会跳转到一个虚拟的吸收态 s_T ，并返回奖励值0。
2. 从 s_T 出发，不论采取什么动作，一定会跳转回这个虚拟的吸收态 s_T ，并返回奖励值0。

由此将有限长的时间步扩展到了无限长，因为环境会陷入到 s_T 的死循环中。

不过，上式实际上很难优化，要求遍历整个状态空间和时间步空间。具体来说，该式要求计算每个时间步上到达每个状态的概率。一方面，这在**计算成本上是无法容忍的**；另一方面，我们在绝大多数情况下，**无法获得环境的转移概率**，因此无法计算特定时间步下整个状态空间上的概率分布。

那怎么办，我们可以用 Monte Carlo 方法，通过采样来逼近上面的策略梯度公式。这里先把上式转化为期望的形式：

$$\begin{aligned}
\text{上式} &= \sum_{t=0}^{\infty} \sum_{s_t} Pr(s_0 \rightarrow s_t, t, \pi) \sum_{a_t} \pi(a_t | s_t) [\gamma^t Q_\pi(s_t, a_t) \nabla \log \pi(a_t | s_t)] \\
&= \sum_{t=0}^{\infty} E_{s_t} \sum_{a_t} \pi(a_t | s_t) [\gamma^t Q_\pi(s_t, a_t) \nabla \log \pi(a_t | s_t)] \\
&= \sum_{t=0}^{\infty} E_{s_t} E_{a_t} [\gamma^t Q_\pi(s_t, a_t) \nabla \log \pi(a_t | s_t)] \\
&= \sum_{t=0}^{\infty} E_{s_t, a_t} [\gamma^t Q_\pi(s_t, a_t) \nabla \log \pi(a_t | s_t)] \\
&= E_{s_0, a_0, s_1, a_1, \dots} \sum_{t=0}^{\infty} [\gamma^t Q_\pi(s_t, a_t) \nabla \log \pi(a_t | s_t)] \\
&= E_\tau \sum_{t=0}^{\infty} [\gamma^t Q_\pi(s_t, a_t) \nabla \log \pi(a_t | s_t)]
\end{aligned}$$

其中 $\tau = [s_0, a_0, s_1, a_1, \dots]$ 是按照策略 π rollout 出来的状态动作的轨迹。可以看出，将 $\gamma^t Q_\pi(s_t, a_t) \nabla \log \pi(a_t | s_t)$ 这一项，先在时间步 t 上求和，再关于轨迹 τ 取期望，就得到了策略

梯度。至此，Monte Carlo方法就可以很简单地结合进来，我们先将将 E_τ 替换为采样 N 条轨迹 $[\tau^1, \dots, \tau^N]$ 。并定义其中第 n 条轨迹为 $\tau^n = \langle s_0^n, a_0^n, r_0^n, \dots, s_{T_n-1}^n, a_{T_n-1}^n, r_{T_n-1}^n \rangle$ ，轨迹长度为 T_n 。最后对结果取平均：

$$\begin{aligned} & E_\tau \sum_{t=0}^{\infty} [\gamma^t Q_\pi(s_t, a_t) \nabla \log \pi(a_t | s_t)] \\ &= \frac{1}{N} \sum_{n=1}^N \sum_{t=0}^{T_n-1} [\gamma^t Q_\pi(s_t^n, a_t^n) \nabla \log \pi(a_t^n | s_t^n)] \end{aligned}$$

注意到 $Q_\pi(s_t^n, a_t^n) = E_{s_{t+1}^n, a_{t+1}^n, s_{t+2}^n, a_{t+2}^n, \dots | s_t^n, a_t^n} \left[\sum_{l=t}^{T_n-1} \gamma^l r_l^n \right]$ ，因此从期望角度二者也是可以替换的。

当我们的算法没有显式地估计 $Q_\pi(s_t^n, a_t^n)$ 时，可以定义 $G_t(\tau^n) = \sum_{l=t}^{T_n-1} \gamma^l r_l^n$ （即最朴素的策略梯度），并用它替换 $Q_\pi(s_t^n, a_t^n)$ ，另外再将式中的 γ^t 省略掉（是一种更简便的近似），就得到了实际使用的策略梯度公式：

$$\frac{1}{N} \sum_{n=1}^N \sum_{t=0}^{T_n-1} [G_t(\tau^n) \nabla \log \pi(a_t^n | s_t^n)]$$

P.S. 策略梯度相关的代码示例可以参考我们的 [“算法-代码” 注解文档](#)